# Seminararbeit Red-Black Trees

Herr Yannik Höll

16. Oktober 2021

# Inhaltsverzeichnis

1	Ein	$\operatorname{leitung}$	4			
2	Def	inition Binary Tree & Red Black Tree	4			
	2.1	Binary Tree	5			
		2.1.1 Nomenklatur spezieller Knoten	5			
		2.1.2 Weiter Definitionen	5			
		2.1.3 Algorithmen	5			
	2.2	Red Black Tree	7			
		2.2.1 Erweiterung der Algorithmen	8			
3	Imp	olementierung	11			
	3.1	Generics in C	11			
	3.2	Knoten als Struct	12			
	3.3	Suche nach Knoten	13			
	3.4	Einfügen von Knoten	13			
		3.4.1 Einfügen des neuen Knotens	13			
		3.4.2 Balancieren des Baums (Einfügen)	14			
	3.5	Löschen von Knoten	16			
		3.5.1 Austauschen mit Blatt	17			
		3.5.2 Balancieren des Baumes (Löschen)	18			
	3.6	Generische Baumtraversierung	19			
	3.7	Fehlerbehandlung	20			
4	Imp	olementierungsvarianten	21			
	4.1	Rekursive Implementierung	21			
	4.2	Kekule Zahlen	21			
	4.3	n-rote Knoten erlauben	21			
5	Benchmarks 23					
	5.1	Durchführung	23			
	5.2	Red-Black-Tree vs. Binary Tree	23			
	5.3	Recursive vs. Iterativ	$\frac{24}{24}$			
6	<b>Z</b> eif	tkomplexität	25			

# Abbildungsverzeichnis

1	Beispielhafte Abbildung eines Binärbaums	5
2	Baumrotationen Beispiel	7
3	Worst Case Binary Tree (BT)	7
4	Valider Red Black Tree (RBT)	8
5	Kein RBT; Erfüllt Eigenschaft 2 und 3 nicht	8
6	Beispiel RBT	8
7	Programmablaufplan Einfügen	8
8	Programmablaufplan Löschen	9
9	1. Fall	0
10	2. Fall	0
11	3. Fall	0
12	4. Fall	0
13	Vergleich Laufzeit RBT/BT	3
14	Vergleich der Höhen	4
15	Vergleich Rekursive/Iterative Implementierungen	4
16	Zeit-Komplexität	5
17	Worst Case RBT: Pfad mit alternierender Farbe	5

# 1 Einleitung

Eine Möglichkeit Daten so geordnet zu speichern sind so genannte Baumdatenstrukturen. Diese Speichern Werte geordnet nach einem bestimmten Schlüssel. Eine sehr einfache Baumimplemntierung ist der BT welcher jeweils nur 2 Abzweigungen pro Knoten besitzt (rigorose Baumdefinition in Kapitel 2). Leider hat diese naive Variante der Datenstruktur einige Probleme, welche vorallem beim Einfügen der Daten in geordneter Reigenfolge entstehen. Um diese Probleme zu umgehen kann man die Algorithmen zum Einfügen und Entfernen neuer Datensätze so anpassen, dass die Baumstruktur performanter wird. Ein möglicher besserer Ansatz sind die RBTs.

Diese Arbeit beschreibt wie sich RBT von normalen BTs unterscheiden. Es wird ausführlich beschrieben, wie normale BTs funktionieren und wie man ihre Algorithmen erweitert um RBTs zu erhalten. Dazu wurden jeweils beide Datenstrukturen in der Programmiersprache C implementiert. Auf den jeweiligen Quelltext wird auch eingegangen um auf bestimmte Schwierigkeiten und Besonderheiten und den Implementierungen einzugehen. Zudem werden die Ergenisse von Benchmark analysiert, welche zeigen sollen, dass RBTs tatsächlich besser Laufzeiteigenschaften haben als die Standimplementierung der BTs. Außerdem wird auf die Speicher- und Zeitkomplexität der beiden Datenstrukturen eingegangen und wie sich vorallem der RBT im Worst Case verhält. Der Code, welcher hauptsächlich im Abschnitt 3 zu sehen sind, sind Auschnitte aus der echten Implementierung, aus denen aufgrund von Platzgründen die gesamte Fehlerbehandlung entfernt wurde. Meistens handelt es sich nur um Ausschnitte. Wenn der Leser den gesamten Quellcode sehen möchte, muss er in die Implementierung in C schauen.

## 2 Definition Binary Tree & Red Black Tree

Bäume ganz allgemein sind anders als z.B. Arrays und Listen keine lineare Datenstrukturen, in denen alle Daten hintereinander liegen, sondern haben Verzweigungen, die durch bestimmte Eigenschaften in den Daten zu stande kommen. Eine formal mathematische Definition von Bäumen lautet wie folgt:

#### Definition 1. Baum

Ein Baum T ist eine endliche Menge an Knoten mit folgenden Eigenschaften:

- Es gibt einen speziellen Knoten k, den man Wurzel nennt.
- Alle anderen Knoten sind in  $n \geq 0$  disjunkte Mengen  $T_1, \dots, T_n$  unterteilt, die selbst auch wieder Bäume sind und die man Unterbäume nennt.

Durch diese Definition kann man direkt das Verhältnis zwischen der Wurzel und den anderen Knoten erkennen. Die Wurzel ist den anderen Knoten übergeordnet. Zudem handelt es sich um eine rekursive Definition, weil wir den Baum mithilfe von sich selbst definiert wird. Das soll nochmal verdeutlichen, dass es sich grundlegend um eine rekursive Datenstruktur handelt. Alle Algorithmen, die man auf Bäume anwendet, können rekursiv definiert werden, was in den folgenden Kapiteln verdeutlicht [Knu68, S. 308]

## 2.1 Binary Tree

Der Binary Tree (engl. Binärbaum) ist eine spezielle Art von Baum, für den nach Definition 1 einfach  $n \leq 2$  gelten muss. D.h. für jeden Knoten im Baum gibt es maximal 2 Unterbäume. Man kann diesen Baum jetzt als 3-Tupel (l,k,r), wobei l und r den linken bzw. rechten Unterbaum darstellen und k die Wurzel. Ich spreche hier über sortierte Binary Trees bzw. Binary Search Trees, werde diese aber absofort trotzdem einfach als Binary Tree bezeichnen. Eine entscheidene Eigenschaft ist, dass alle Knoten, die sich in l befinden kleienr als die Wurzel k sind und alle Knoten in r größer. Das ist auch der Grund, warum man von geordneten Bäumen spricht. [San08, S. 147]

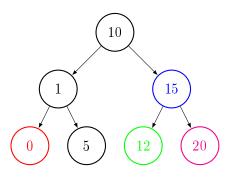


Abbildung 1: Beispielhafte Abbildung eines Binärbaums

## ${f 2.1.1}$ Nomenklatur spezieller Knoten

In Abbildung 1 ist ein Beispiel eines Binary Trees zu sehen. Nun bekommen bestimmte Knoten in diesen Bäumen spezielle Namen,

damit man einfach über sich sprechen kann, ohne immer eine konkrete Lagebeschreibung machen zu müssen. In diesem Baum ist der Knoten mit der Nummer 10 die Wurzel. Wenn wir die Pfeile von der 10 aus entlang gehen gelangen wir zu den Knoten 1 und 15. Diese werden als Children (engl. Kinder) von 10 bezeichnet. Genauso sind 0 und 5 die Childer von 1 uind 12 und 20 die Children von 15. Umgekehrt bezeichnet man 10 als Parent (engl. Elternteil) von 1 und 15. Die Knoten 0, 5, 12 und 20 sind die Leaves (engl. Blätter) des Baums. Das sind genau die Knoten, die keine Children haben. Grundsätzlich ist es so, dass jeder Knoten im Baum einen Parent hat außer die Wurzel. Alle Knoten, die den gleichen Parent haben, bezeichnet man als Siblings (engl. Geschwister). In unserem Beispiel sind 0 und 5, 12 und 20 und 1 und 15 Siblings. Der Parent eines Parent ist der Grandparent (engl. Großelternteil). Also ist beispielsweise die 10 der Grandparent von der 0. [Knu68, S.311]

Da die folgeneden Benennungen nun ein bisschen komplizierter werden, kommen nun die Farben zum Einsatz. Von der 0 ausgehend ist der Sibling des Parents (blau) der Uncle (engl. Onkel) der 0. Das wäre also hier die 15. Und die Childer vom Uncle werden als Niece (engl. Nichte) (grün, die 12) und Nephew (engl. Neffe) (magenta, die 20) bezeichnet. Die Niece ist immer der Knoten, der in die selbe Richtung zeigt, wie der Knoten auf dem man sich bezieht und der Nephew somit, der, der in die entgegengesetzte Richtung zeigt. Diese Unterscheidung wird später in einem Algorithmus wichtig werden.

## 2.1.2 Weiter Definitionen

Man bezeichnet einen Knoten als **Leaf** (engl. Blatt), wenn er keine Children besitzt. [Sed90, S. 36] Dementsprechend bezeichnet man einen Knoten als **Halfleaf** (engl. Halbblatt), wenn er nur ein Child hat.

Als **Path** (engl. Pfad) in einem Baum bezeichnet man eine Folge von Knoten, die paarweise verschieden sind und 2 Knoten im Baum (oder allgemein in einem Graphen) verbinden. [Sed90, S. 36]

#### 2.1.3 Algorithmen

Die **Suche** in BT ist direkt durch ihre Eigenschaften zu definieren. Da alle Knoten in linken Unterbaum kleiner sind und alle Knoten rechts größer kann man einfach rekursiv eine Suche wie folgt definieren:

#### Algorithm 1 Suche im BT

```
1: procedure SEARCH(node, key)
2: if node == NULL then
    return NULL
3: if node \rightarrow key == key then
    return node
4: else if node \rightarrow key < key then
    return Search(node \rightarrow left, key)
5: else
    return Search(node \rightarrow right, key)
```

node ist ein Pointer auf einen Knoten im Baum, key ist der zu suchende Schlüssel. node→right und node→left sind jeweils Pointer zum rechten und linken Unterbaum. t

Letzendlich funktioniert der Algorithmus so, dass man bei der Wurzel beginnt. Als erstes überprüft man, ob man bei einem NULL Pointer angekommen ist, was bei mir der Sentinel-Wert für einen leeren Knoten ist. Das zeigt an, dass der Schlüssel im Baum nicht vorhanden ist, und es wird direkt NULL ausgegeben. Dann wird abgefragt, ob der aktuelle Knoten node bereits den richtigen Schlüssel hat. Wenn das der Fall ist, dann wird er ausgegeben. Ansonsten wird die Suche beim linken bzw. rechten Unterbaum fortgesetzt, je nachdem ob key kleiner oder größer als node—key ist. Das wird durch einen rekursiven Aufruf der Search-Funktion realisiert. [Sed90, S. 203]

Das **Einfügen** ist im Grunde das selbe wie die Suche, nur das man sucht, bis man NULL erreicht. An dieser Stelle wird dann der neue Knoten eingefügt. Da man keinen Pointer auf den Parent hat, muss man diesen jeweils zwischenspeichern. [Sed90, S. 205] Da der Algorithmus fast genauso wie die Suche definiert ist, wird hier auf Pseudocode verzichtet.

Die letzte wichtige Operation das **Löschen** von Knoten. Diese ist wohl die komplizierteste, weil der naive Ansatz, einfach den Knoten zu entfernen, nicht funktioniert. Die einzigen Knoten, die man Entfernen kann, ohne dass der Baum in 2 Teile zerfällt, sind die Leafs. Um den Knoten, der gelöscht werden soll, zu finden, kann man die vorhin definierte Suche verwenden. Deswegen muss man diesen Knoten, mit einem Leaf austauschen. Dabei muss aber die Inorder-Traversierungsreihenfolge erhalten bleiben (Def. siehe Kapitel 3.6). Diese hat dann den nächstkleineren bzw. -größeren Schlüssel. Nach dem Austausch ist der zu löschende Knoten ein Leaf oder Halfleaf und kann sicher entfernt werden. Im Falle eines Halfleafs muss dann noch das Kind des entfernten Knotens als Kind des entsprechenden Parents festgelegt werden.

#### Algorithm 2 Löschen im BT

```
1: \mathbf{procedure} \ \mathsf{PREORDER}(\mathsf{root}, \mathsf{key})
2: node \leftarrow Search(root, key)
3: \mathbf{if} \ node == NULL \ \mathbf{then}
\mathbf{return}
4: node \leftarrow SwapToLeaf(node)
5: \mathbf{if} \ IsHalfLeaf(node) \ \mathbf{then}
6: SetChild(GetParent(node), GetChild(node))
7: Delete(node)
```

Genaue Implementierungen der hier im Pseudocode nicht gezeigten Funktionen (IsHalfLeaf, GetParent, GetChild, SetChild) werden dann im Kapitel 3 genauer besprochen.

Als letztes wird hier noch ein Algorithmus besprochen, der zwar mithilfe des algemeinem BT definiert werden kann, aber erst in den Algorithmen des RBT seine Anwendung findet. Die Rede ist von den **Baumrotationen**, die die Struktur des Baumes direkt verändern, ohne die Inorder-Reihenfolg durcheinander zu bringen. Hier gibt es zwei Möglichkeiten, eine Rotation nach links bzw. nach rechts.

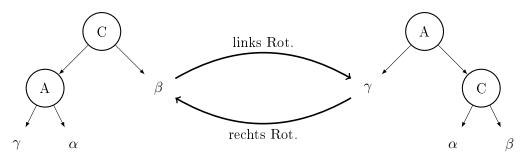


Abbildung 2: Baumrotationen Beispiel

In der Abbildung 2 kann man diese Algorithmen angewandt auf einen Unterbaum sehen.  $\alpha$ ,  $\beta$  und  $\gamma$  sind in diesem Fall beliebige Unterbäume oder könnten auch leer sein. Man kann erkennen, dass durch den Algorithmus die Inorder-Reihenfolge erhalten bleibt. Die beiden Operationen sind Inversen der jeweils anderen. Außerdem wird ein Knoten eine Ebene im Baum nach oben verschoben und dessen Parent um eine nach unten. Ein Unterbaum wechselt die Parents. [CLRS09, S. 313]

### 2.2 Red Black Tree

Die Motivation für RBTs ist der Worst Case von den BTs. Wenn man hintereinander einfach geordnet Elemente in diese einfügt, dann wird immer eins der beiden Children besetzt je nach Ordnung der Daten. Das führt zu einer Datenstruktur, die eher einer linearen Liste gleicht und deswegen schlechtere Zeitkomplexität besitzt.

Grundsätzlich hat der Red Black Tree auch alle Eigenschaften eines normalen Binary Trees. Jedoch erhält jeder Knoten eine zusätzlich Eigenschaft, die üblicherweise als Farbe bezeichnet wird. Dabei kann ein Knoten rot oder schwarz sein.

Nun werden zusätzlich Regeln eingeführt, die ein Baum erfüllen muss, damit er ein Red Black Tree ist.

## **Definition 2.** Eigenschaft RBT

- 1. Die Wurzel ist immer schwarz.
- 2. Die Children eines roten Knotens sind schwarz.
- 3. Jeder Path zwischen der Wurzel und einem Leaf hat die selbe Anzahl an schwarzen Knoten.

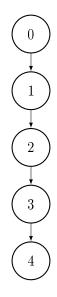


Abbildung Worst Case BT

3:

Die 2. Regel ist äquivalent zur Aussage, dass nicht 2 rote Knoten aufeinander folgen dürfen. [Sed90, S. 220f]

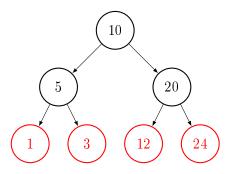


Abbildung 4: Valider RBT

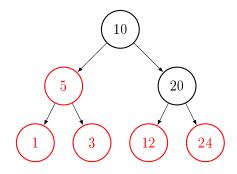


Abbildung 5: Kein RBT; Erfüllt Eigenschaft 2 und 3 nicht

Abbildung 6: Beispiel RBT

Das Balancieren funktioniert im Grunde so, dass man nachdem man Knoten in den Baum eingefügt hat bzw. aus dem Baum entfernt hat nur dafür sorgen muss, dass diese 3 Regeln wieder erfüllt werden. Dafür muss man die Algorithmen des normalen BT um einen Teil erweitern, der überprüft, ob irgendeine der Eigenschaften nicht erfüllt ist und dann Knoten umfärben und Baumrotationen durchführen, bis das wieder für alle 3 der Fall ist.

## 2.2.1 Erweiterung der Algorithmen

Die **Suche** im Baum muss nicht verändert werden, da die Eigenschaften keinen Einfluss auf sie haben. [Sed90, S. 221]

Colorflip ist ein zusätzlicher Algorithmus, der dann beim Balancieren gebraucht wird. Er ändert einfach die Farben bestimmter Knoten von rot nach schwarz bzw. umgekehrt.

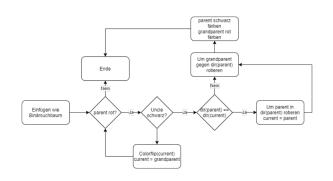


Abbildung 7: Programmablaufplan Einfügen

Beim Einfügen ist die erste Neuerung, dass die neuen Knoten immer rot sind. Also kann nur Eigenschaft zwei invalidiert werden, nach dem dieser Algorithmus durchgeführt wurde. Das passiert genau dann, wenn der Parent des eingefügten Knotens rot war. Man erweitert den Standardalgorithmus nun um eine weitere Funktion, die diesen Fall überprüft und dann nach bestimmten Kriterien Rotationen und Colorflips durchführt, bis der Baum wieder ein valider RBT ist.

Der Algorithmus wird iterativ auf den Baum angewandet, solange, bis der Parent des

aktuellen Knotens nicht rot ist. Begonnen wird beim neu eingefügten Knoten. Der 1. Fall tritt ein, wenn der Uncle des behandleten Knotens rot ist. Dann wird einfach ein Colorflip ausgeführt und man setzt den Algorithmus beim Grandparent fort. Im 2. Fall ist der Uncle schwarz und der aktuelle Knoten in die selbe Richtung zeigt, wie der Parent. Dann wird eine Rotation ausgeführt in die Richtung, in die der Parent zeigt, als Linksrotation wenn es nach links zeigt und ansonsten eine Rechtsrotation.

Das schöne hier ist nun, dass dieser zweite Fall direkt zum 3. Fall führt. Er kann jedoch auch erreicht werden, wenn der Parent und der aktuelle Knoten in unterschiedliche Richtungen zeigen. Dann wird in die Richtung des Parents um den Grandparent rotiert, der Parent schwart und der Grandparent rot gefärbt und der Algorithmus wird beendet. So braucht man maximal 2 Rotationen oder h/2 Colorflips (h ist die Länge des längsten Pfades von der Wurzel zu einem Leaf oder wird auch Höhe des Baums genannt).

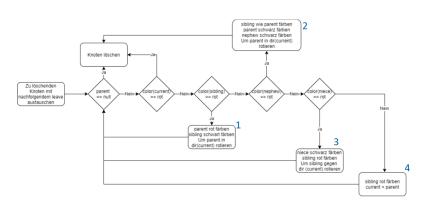


Abbildung 8: Programmablaufplan Löschen

Der letzten Algorithmus, der angepasst werden muss, ist das **Löschen** von Knoten im Baum. Es muss wieder einen Algorithmus geben, der den Baum nach dem Entfernen eines Knotens wieder zu einem validen RBT macht.

Nun kommt es zu einer Verletzung der Regeln, wenn man einen schwarzen Knoten entfernt, weil dann nicht mehr alle Pfade die selbe Anzahl von Ihnen haben. Der folgende Algorithmus, desses Ablaufplan in Abbildung 8 dargestellt ist wird nach dem Algorithmus ausge-

führt, der den zu löschenden Knoten mit einem Blatt austauscht, aber vor dem tatsächlichen Entfernen aus dem Baum. Auch hier gibt es wieder eine Fallunterscheidung. Diesmal jedoch mit 4 Fällen. Diese sind auch in der Abbildung entsprechend markiert. Als erstes wird einmal überprüft, ob die Wurzel entfernt wird (also ob der Knoten überhaupt einen Parent hat) oder ob er rot ist. In diesem Fällen ist der Algorithmus sofort fertig und man kann sicher Löschen.

Anderfalls muss nun das Rebalancieren beginnen. Wenn der Sibling des aktuellen Knotens rot ist, dann wird der Parent rot gefärbt, der Sibling schwarz und es wird in Richtung des aktuellen Knotens um den Parent rotiert. Wenn der Sibling rot ist, werden dann Niece und Nephew überprüft. Wenn der Nephew rot ist, dann wird der 2. Fall behandelt. In diesem Fall wird der Sibling rot eingefärbt, der Parent und Nephew schwarz und es wird in Richtung des aktuellen Knotens um den Parent rotiert. Das schöne hier ist, dass nach diesem Fall der Baum balanciert ist und das entfernen des Knotens durchgeführt werden kann. Sonst geht es damit weiter, dass die Farbe der Niece überprüft wird. Ist sie rot, dann wird der Algorithmus für den 3. Fall ausgeführt. Hier wird die Niece schwarz gefärbt, der Sibling rot und dann um den Sibling in Richtung des aktuellen Knotens rotiert. Und wenn alle oben genannten Bediengungen nicht zutreffen, dann sind alle genannten Knoten schwarz und es wird einfach der Sibling rot gefärbt und der Algorithmus beim Parent fortgesetzt. Das ist der 4. Fall. Die 4 Abbildungen unten illustrieren die Unterbäume für die 4 Fälle. Der Knoten, der mit x bezeichnet ist, ist der zu entfernende Knoten. Es ist ein Leaf oder Halfleaf per Definition.

Als kurze Erklärung warum die Algorithmen so definiert sind, muss man erstmal das Problem definieren. Im Unterbaum des zu löschenden Knotens fehlt ein schwarzer Knoten. Nun gibt es 2 Ansätze, dieses Problem zu lösen. Entweder man versucht, einen neuen schwarzen Knoten zu erzeugen, damit die Balance wieder hergestellt wird. Das sind die Fälle 1, 2, 3. Allerdings muss dabei sichergestellt werden, dass die anderen Regeln des RBT danach weiterhin gelten. Oder man probiert aus dem benachbarten Unterbaum einen schwarzen Knoten zu entfernen (Fall 4). Hier besteht nun das Problem, dass sich die Anzahl der Knoten durch den Parent und dessen Sibling unterscheiden. Also muss man

auch einen schwarzen Knoten aus dem Unterbaum des Siblings des Parents entfernen. Und so weiter bis man an der Wurzel ankommt. Auch hier kann man zeigen, dass die Anzahl der Ausführungen der einzelnen Algorithmen für die Fälle begrenzt ist, der gesamte Algorithmus also terminiert.

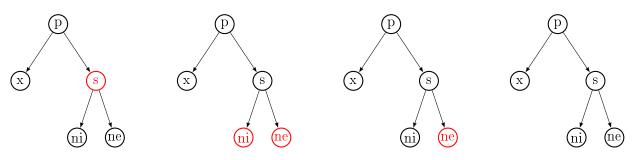


Abbildung 10: 2. Fall

Abbildung 11: 3. Fall

Abbildung 12: 4. Fall

## 3 Implementierung

Wie schon in den vorhergenden Kapiteln beschrieben, handelt es sich bei den Bäumen um eine generische Datenstruktur, in die der Nutzer beliebig Daten mit einem bestimmten Schlüssel einfügen kann.

Die Implementierung stellt deswegen 3 Funktionen bereit, mit denen man nach einem bestimmten Schlüssel im Baum suchen kann, man einen neuen Schlüssel zusammen mit einem Datensatz einfügen kann und man einen Schlüssel und den Datensatz wieder aus dem Baum löschen kann.

#### 3.1 Generics in C

Bei der Implementierung in C gab es dabei einige Schwierigkeiten, die man lösen musste. Es beginnt damit, dass C keine objekt-orientierte Programmiersprache ist und keine eingebaute Möglichkeit für Generics hat. Nun kann man dieses Problem auf verschiedene Weisen lösen. Den Wert, der bei jedem Knoten des Baums gespeichert werden soll, lässt sich ganz simple aus Void-Pointer (void\*) implementieren, sodass man die Daten beispielsweise auf dem Heap ablegen kann und mithilfe eines Casts den Pointer der Daten (z.B. int\*) zu void\* umwandeln kann. Das erlaubt es, beliebige Datentypen und sogar Struct in den Baum einzufügen. Diese Variante ist möglich, da die Nutzerdaten auf die Suche nach einem Knoten keinen Einfluss haben.

Anders ist es bei der Implementierung der Schlüssel. Hier muss sichergestellt sein, dass diese untereinander vergleichbar sind, sodass man die Suche, wie im Kapitel 2 beschrieben, durchführen kann. Man könnte Gebrauch von Unions in C machen, in denen man die numerischen Datentypen als mögliche Schlüssel anbietet.

```
union RBTreeKey {
char c;
short s;
int i;
long long l;
float f;
double d;
}
```

Zusätzlich müsste man dazu noch angeben, welchen Datentyp man in seinem Code nutzt (z.B. mithilfe einer Macro). Dieser Ansatz ist allerdings sehr unflexibel, weil man auf die Datentypen, die im union RBTreeKey vom Programmierer festgelegt sind, beschränkt ist.

Ein bessere Ansatz ist es, eine Macro zu definieren, die den Typen der Schlüssel definiert. Zusätzlich kann man noch eine 2. und 3. Macro definieren, die die Kleiner-Als- und Ist-Gleich-Operatoren definieren. Das ermöglicht es beliebige Datentypen als Schlüssel zu verwenden (sogar Structs), solange man die Vergleichsmacros definieren kann.

```
#define T int
2 #define TEQUAL(x, y) ((x) == (y))
3 #define TLESS(x, y) ((x) < (y))
```

Genau diese Implementierung wurde auch gewählt. Im Usercode müssen nur der Typ T und die Vergleichsoperationen TLESS und TEQUAL definiert werden. Einziger Nachteil ist, dass man im selben Quelltext nicht meherere verschidene Varianten von Schlüsseldatentypen nutzen kann.

#### 3.2 Knoten als Struct

Wie schon in Kapitel 2 beschrieben, sind Bäume nichts anders als ein 3-Tupel (l, k, r). l und r sind die Unterbäume und k ist die Wurzel des Baumes (hier als k bezeichnet wegen Schlüssel  $\cong$  Key). Jeder Knoten enthält somit seinen Schlüssel und eine Referenz auf den linken und rechten Unterbaum. In  $\mathbf{C}$  wird der Baum nun als verkettete Liste von Knoten dargestellt Im struct Node haben wir somit den generischen Schlüssel T \*key und zugehörigen Wert void \*value</code>. Zusätzlich speichern wir Pointer zum linken und rechten Child, welche die Wurzeln der entsprechenden Unterbäume sind. Zusätzlich wird auch noch ein Pointer zum Parent gespiechert, da man diesen ziemlich oft in den Algorithmen zum Einfügen und Löschen von Knoten benötogt und man so den Quellcode etwas vereinfachen kann.

Natürlich gibt es im Knoten auch noch ein Feld, welches die Farbe des Knotens speichert. Diese ist später wichtig, weil sie von zum balancieren des Baumes benötigt wird. Dieses findet während des Einfügens und Löschens neuer Knoten in den Baum statt. Die Werte für dieses Feld im Struct werden durch die Macros RB\_TREE\_RED und RB\_TREE\_BLACK definiert.

Zusätzlich existiert ein weiter Struct für den Baum selbst, welcher allerdings nur als Handle für die Funktionen dient. Er speichert die Wurzel und die Anzahl der eingefügten Knoten. Diese wird benötigt, damit man die Worst-Case-Höhe des Baums berechnen kann <sup>1</sup>.

```
#define RB_TREE_RED
  #define RB_TREE_BLACK
                             0 U
  struct Node;
  struct Node {
       void *value;
      T *key;
9
       struct Node *left;
12
       struct Node *right;
13
       struct Node *parent;
14
15
       uint8_t color;
  };
16
17
  struct RBTree {
18
       struct Node *root;
19
       size_t node_count;
21
22 };
```

Zusätzlich existieren 2 Helfer-Funktionen, die jeweils eine Instanz von diesem Struct für den Nutzer erstellen und auch wieder freigeben. Der Baum wird durch die create\_tree Funktion auf dem Heap abgespeichert und aus wird lediglich ein Pointer zu ihr ausgegeben. Das Löschen des Baumes wird durch free\_tree implementiert. Dieses ist auch auf keinen Fall trivial, weil es Bottom-Up durchgeführt werden muss und somit nicht durch den Nutzer selbst implementiert werden sollte.

Die Signatur dieser Funktionen sieht man im unteren Listing.

```
struct RBTree* create_tree();
void free_tree(struct RBTree *rbtree);
```

#### 3.3 Suche nach Knoten

Eine der wichtigsten Operation, auf die auch später das Einfügen und das Löschen von Knoten aufbaut ist die Suche im Baum. Diese ist normalerweise als rekursiver Algorithmus definiert, lässt sich aber auch ziemlich einfach iterativ implementieren. Grundsätzlich wurde in der Implementierung auf Rekursion verzichtet und immer entweder ein iterativer Ansatz verwendet oder ein selbst implementierter Stack, um Stackoverflows zu vermeiden.

Die Funktion, die die Suche implementiert, akzeptiert eine Pointer zum Baum, den zu suchenden Schlüssel und einen Pointer, in der der Pointer des gefundenen Knotens geschrieben werden kann, falls vorhanden.

```
uint8_t search_node(struct RBTree* rbtree, T* key, struct Node** node);
```

Der Algorithmus selbst speichert den aktuellen Knoten in der Variable struct Node\* current beginnend bei der Wurzel. Anschließen wird iterativ entweder der linke oder der rechte Unterbaum besucht, abhängig davon, ob der Schlüssel, nachdem gesucht wird, kleiner oder größer als der Schlüssel des aktuellen Knotens ist. Wenn er kleiner ist wird der linke Unterbaum besucht sonst der Rechte. Dies geschiet, in dem current entweder das linke oder rechte Child des aktuellen Knotens zugewisen wird.

Die while-Schleife bricht ab, wenn der Schlüssel gefunden wurde oder das nächste Child NULL ist. Im letzteren Fall wird ein Fehlercode returned und dem Ausgabe Pointer NULL zugewiesen, weil der Schlüssel nicht im Baum vorhanden ist. Ansonsten kann man der Ausgabe einfach current zuweisen und den Erfolgswert returnen, der anzeigt, dass es keinen Fehler gab (mehr dazu in Kapitel 3.7).

```
struct Node *current = rbtree->root;

while (current != NULL) {
    if (TEQUAL(*(current->key), *(key))) break;
    current = (TLESS(*key, *(current->key))) ? current->left : current->right;
}

if (current == NULL) {
    *node = NULL;
    return RB_TREE_KEY_ERROR;
}

*node = current;
return RB_TREE_SUCCESS;
```

### 3.4 Einfügen von Knoten

#### 3.4.1 Einfügen des neuen Knotens

Eine weiter wichtige Operation ist das Einfügen von Daten in den Baum. Dabei müssen die zwei Eigenschaften der Datenstruktur erhalten bleiben, die sortierte Reihenfolge und dass der Baum ein valider RBT ist. Das Listing unten zeigt die Signatur der Funktion, die das Einfügen durchführt. Sie akzeptiert einen Pointer zu einem Baumstruct struct RBTree\* rbtree, einen Pointer zum Schlüssel des neuen Knotens T\* key und optional Daten, die auch im Knoten gespeichert werden sollen, void\* value (dieser Wert kann auch NULL sein).

```
uint8_t insert_node(struct RBTree* rbtree, T* key, void* value);
```

Die Implementierung sorgt erst dafür, dass der neue Knoten an die richtige Stelle im Baum eingefügt wird und stellt danach (wenn nötig) sicher, dass es immer noch ein valider RBT ist.

Das Einfügen des Knotens in den Baum kann nun analog zur Suche implementiert werden. Der Unterschied liegt darin, dass man den Baum durchsucht, bis man bei NULL ankommt. Beim Suchen war das der Fehlerfall, dass es keinen Knoten mit dem zu suchenden Schlüssel gab, aber während des Einfügens ist das die Annahme die getroffen wird. Der Schlüssel, den den Nutzer neu hinzufügen will, sollte noch nicht im Baum enthalten sein. Damit ist der erreichte NULL-Pointer nach der Logik des Baums genau die Stelle, an der der neue Knoten mit dem neuen Schlüssel eingefügt werden muss.

Der Grund, warum hier der Pointer zum Vorgänger-Knoten previous zusätzlich gespeichert werden muss, ist, dass NULL nicht auf eine valide Structinstanz zeigt, sondern lediglich anzeigt, dass es keinen Knoten an dieser Stelle gibt. Somit kann man auch nicht den Parent von NULL abfragen und man muss diese Information in einer zustätzlichen Variable zwischenspeichern.

```
struct Node *previous = NULL;
struct Node *current = rbtree->root;

while (current != NULL) {
    previous = current;
    current = (TLESS(*key, *(previous->key))) ? previous->left : previous->right;
}
```

Nun wird eine neue Instanz von struct Node erstellt. Das erledigt die Helfer-Funktion \_create\_node, welche den neuen Knoten auf dem Heap abspeichert und den Pointer auf ihn ausgibt. In ihr wird auch direkt sichergestellt, dass der neu allozierte Heap-Speicher korrekt initialisiert wird und die Farbe auf rot gesetzt. Der neue Knoten muss dann an den Parent vom erreichten NULL-Pointer entweder links oder rechts angehangen werden.

```
struct Node *new_node = _create_node(key, value);
if (TLESS(*key, *(previous->key))) {
    previous->left = new_node;
} else {
    previous->right = new_node;
}
new_node->parent = previous;
```

Es gibt auch noch den Spezialfall, dass ein Knoten in einen noch leeren RBT eingefügt werden soll. Hier muss dann der Pointer auf die Wurzel im struct RBTree gesetzt werden. Deswegen wird bevor der oben angebene Algorithmus ausgeführt wird, noch überprüft, ob der Nutzer den leeren Baum als Eingabe in die Funktion gegeben hat. Das Gute ist, dass man in diesem Fall auch gar nicht den Baum durchsuchen muss, sondern sofort weiß, dass der neue Knoten die Wurzel selbst ist. Es darf allerdings nicht vergessen werden, dass durch \_create\_node die Farbe des neuen Knotens auf rot gesetzt wurde. Sie muss deswegen noch zu schwarz geändert werden, weil die Wurzel des RBT immer schwarz sein muss.

```
if (rbtree->root == NULL) {
   rbtree->root = new_node;
   rbtree->root->color = RB_TREE_BLACK;
4 }
```

#### 3.4.2 Balancieren des Baums (Einfügen)

Nach dem Einfügen in den Baum, kann es dazu kommen, dass die Regeln des RBTs verletzt werden. Dieser Fall tritt dann ein, wenn der Parent des neuen Knotens rot ist, denn dann sind 2 aufeinanderfolgende rote Knoten im Baum, was nicht der Fall sein darf (siehe 2).

Wenn der obige Fall eintritt, muss einer der in Kapitel 2 beschriebenen Algorithmen ausgeführt werden, damit der Baum wieder alle Eigenschaften erfüllt und ein valider RBT wird. Das hat den Nebeneffekt, dass der Baum dabei besser im Durchschnitt ausbalanciert wird. In der Implementierung wurden Helferfunktionen implementiert, die den Colorflip und die Rotations am Baum durchführen.

Das untere Listing zeigt einen Auszug aus der Funktion, welche die Baumrotation durchführt (nur die Linksrotation).

```
struct Node *child = start_node->right;
if (start_node == rbtree->root) rbtree->root = child;
child->parent = start_node->parent;

if (start_node->parent != NULL) {
   if (start_node->parent->left == start_node) start_node->parent->left = child;
   else start_node->parent->right = child;
}

start_node->right = child->left;
if (start_node->right) start_node->right->parent = start_node;

child->left = start_node;
start_node->parent = child;
```

Hier zeigt sich der Vorteil der Implementierung als Verkettung von Pointern. Die Rotation kann einfach durch das Austauschen von Child- und Parent-Pointern implementiert werden.

Nachdem die Helferfunktionen besprochen wurden, kann nun endlich mit dem rebalancieren begonnen werden, welches diese nutzt. Die Funktion, die diesen entsprechenden Algorithmus dafür implementiert heißt fix\_tree\_insert. Ihre Signatur befindet sich im unteren Listing.

```
void fix_tree_insert(struct Node *start_node, struct RBTree *rbtree)
```

start\_node ist dabei der Knoten, der die Eigenschaften eines RBT verletzt, also der Knoten, der zuletzt eingefügt wurde.

Unten kann man nun die Implementierung der Funktion sehen. Als erstes werden 2 Pointer angelegt, die den aktuell betrachteten Knoten und seinen Parent speichern. Das ist wichtig, weil es passieren kann, dass der Algorithmus mehrere Schritte benötigt. Das ist auch der Grund, warum sich alles innerhalb einer while-Schleife befindet, nämlich damit solange rebalanciert wird, bis die Abbruchbediengung erreicht wird (siehe Kapitel 2).

Wie schon in Kapitel 2 beschrieben, gibt es verschiedene Fälle, die betrachtet werden müssen. Je nach Farbe des Uncle-Knotens und Richtung des Parents werden Colorflips und Rotationen durchgeführt. Dafür können hier nun die Helferfunktionen, die in den letzten Abschnitten beschrieben wurden genutzt werden. Der Vorteil daran ist, dass diese auch gleich noch bestimmte Fehlerfälle abfangen, sodass man sich viel Codeduplzierung ersparen kann.

Als letztes wird noch die Farbe der Wurzel auf RB\_TREE\_BLACK gesetzt, weil es vorkommen kann, dass sie am Ende rot ist. Die Eigenschaften von RBT schreiben jedoch vor, dass die Wurzel immer schwarz sein muss. Hier wurde bewusst auf eine if-Abfrage verzichtet, um Instruktionen zu sparen.

```
struct Node *current = start_node;
struct Node *parent = start_node->parent;

while (parent != NULL && parent->color == RB_TREE_RED && current->color == RB_TREE_RED) {
   if (parent->parent == NULL) break;
}
```

```
struct Node *uncle = get_uncle(current);
      if (get_color(uncle) == RB_TREE_BLACK) {
9
10
           if (get_direction(parent) != get_direction(current)) {
               rotate(parent, get_direction(parent), rbtree);
12
               current = parent;
               parent = current->parent;
13
          } else {
14
               struct Node *grandparent = get_grandparent(current);
               rotate(grandparent, !get_direction(parent), rbtree);
               parent -> color = RB_TREE_BLACK;
17
               grandparent -> color = RB_TREE_RED;
18
19
          }
      } else if (get_color(uncle) == RB_TREE_RED) {
2.1
           color_flip(current);
22
           if (parent->parent == NULL) break;
23
24
           struct Node *uncle = get_uncle(current);
25
26
           current = get_grandparent(current);
           parent = current->parent;
27
28
29
  }
30
rbtree ->root -> color = RB_TREE_BLACK;
```

#### 3.5 Löschen von Knoten

Die letzte Operation, die die Daten im Baum verändert, ist das Löschen von Knoten. Diese ist wohl auch die komplizierteste Operation, weil sehr viele Fälle betrachten muss und viele und Grenzfälle abfangen muss.

In meiner Implementierung findet das Löschen in 3 Schritten statt. Als erstes wird der Knoten, der gelöscht werden soll, mit einem Blatt des Baumes ausgetauscht, falls er noch keiner ist. Danach kann dieser sicher entfernt werden, ohne dass der Baum in mehrere Bäume zerfällt. Anschließend wird wieder die Balancierung durchgeführt. Alle diese Algorithmen wurden wieder in separate Funktionen extrahiert.

Die Funktion, die der Nutzer meiner Datenstruktur aufruft, um einen Knoten zu entfernen, heißt delete\_node. Sie hat folgende Signatur:

```
uint8_t delete_node(struct RBTree* rbtree, T* key);
```

T\* key ist hier der Schlüssel des Knotens, der gelöscht werden soll.

Es wird damit begonne, dass der Knoten mit dem entsprechenden Schlüssel key gesucht wird. Dafür kann die search-Funktion verwendet werden, die im Kapitel 3.3 etabliert wurde.

```
struct Node *node_to_delete = NULL;
search_node(rbtree, key, &node_to_delete);
```

Als nächstes wird dann der Algorithmus durchgeführt, der den zu löschenden Knoten mit einem Blatt austauscht. Das Blatt, mit dem getauscht wird, wird so gewählt, dass nach der Löschung die Inorder-Traversierungs-Reihenfolge korrekt ist. Das alles wird durch die Funktion swap\_to\_leaf implementiert. Sie gibt dann den Pointer zum Blatt aus x, welches entfernt werden kann.

```
struct Node *x = swap_to_leaf(node_to_delete);
```

Dann wird noch die fix\_tree\_delete-Funktion aufgerufen. Sie ist das Äquivalent zu fix\_tree\_insert, welche nach dem Einfügen den Baum balanciert, aber etwas komplizierter in ihrer Implementierung.

```
fix_tree_delete(x, rbtree);
```

Jetzt wird noch überprüft, ob die Wurzel gelöscht werden soll, was bedeutet, dass sie der einzige Knoten im Baum ist. Hier müssen dann einige Felder im rbtree-Struct verändert werden. Es werden dann alle Pointer, die auf den Knoten zeigen zu NULL geändert, was ihn effektiv aus dem Baum entfernt. Danach wird der zu löschende Knoten freigegeben.

```
if (rbtree->root == x) {
    _free_node(rbtree->root);
    rbtree->root = NULL;
    return RB_TREE_SUCCESS;

if (get_direction(x) == RB_TREE_LEFT_CHILD) x->parent->left = NULL;
else x->parent->right = NULL;

_free_node(x);
```

Es wurden in diesem einführenden Abschnitt einige Funktionen genannt, die noch als Blackbox betrachtet wurden. Auf deren Funktionsweise wird in den nächsten Kapitel näher eingegangen.

#### 3.5.1 Austauschen mit Blatt

Das Austauschen findet in der Funktion swap\_to\_leaf statt, deren Signatur sich im unteren Listing befindet.

```
struct Node* swap_to_leaf(struct Node *node_to_delete);
```

node\_to\_delete ist dabei der Pointer zum Knoten der gelöscht werden soll von delete\_node also somit der Knoten, der ein Blatt werden soll.

In der Funktion selbst muss nun der Knoten mit der oben genannten Eigenschaft gefunden werden. Dies geschiet, in dem man erst im linken Unterbaum von node\_to\_delete des Child sucht, welches sich am weitesten rechts befindet. Und falls es das nicht gibt sucht man im rechten Unterbaum nach dem Knoten, der sich am weitesten links befindet. Das sind die Knoten, die in der Inoreder-Reihenfolge direkt vor bzw. nach dem zu löschenden Knoten kommen. Das wird durch die Helfer-Funktionen get\_next\_smallest bzw. get\_next\_largest. Im unteren Listing kann man beispielhaft die Implementierung einer dieser Funktionen sehen:

```
void get_next_largest(struct Node *start, struct Node **next_largest)

struct Node *current = start;

while (current->left != NULL) current = current->left;

*next_largest = current;

}
```

Wenn keiner der beiden oberen Fälle eintritt, dann ist note\_to\_delete bereits ein Leaf und der Algorithmus gibt den Knoten selbst aus.

Ansonsten werden mithilfe der Funktion swap die Schlüssen und Daten des Leafs und von note\_to\_delete einfach ausgetauscht und es wird der Pointer zum Leaf ausgegeben. Unten kann man die Implementierung für den Fall des linken Unterbaums sehen. Die für den rechten Unterbaum ist eine Aufgabe für den Leser.

```
struct Node *next_smallest = NULL;
get_next_smallest(node_to_delete->left, &next_smallest);
leaf = next_smallest;
swap((void**)&node_to_delete->key, (void**)&next_smallest->key);
swap(&node_to_delete->value, &next_smallest->value);
```

### 3.5.2 Balancieren des Baumes (Löschen)

Ähnlich wie beim Einfügen in den Baum muss auch nach dem Entfernen aus dem Baum rebalanciert werden. Die Signatur, die den entsprechenden Algorithmus implementiert ist so definiert:

```
void fix_tree_delete(struct Node *x, struct RBTree *rbtree);
```

x ist hier der Pointer auf den Knoten, der aus dem Baum gelöscht werden soll. Wir können hier annehmen, dass er ein Leaf ist, denn die swap\_to\_leaf-Funktion wird vorher auf den Knoten der gelöscht werden soll angewandt, sodass immer nur Blätter gelöscht werden müssen.

Ähnlich wie beim Einfügen gibt es auch hier wieder Fälle, die der Code abarbeiten muss, abhängig von der Farbe bestimmter Knoten. Der Algorithmus befindet sich in einer while-Schleife, weil es auch hier wieder passieren kann, dass es mehrere Durchläufe gibt, bevor der Baum balanciert ist.

Die ersten beiden Bediengungen x->parent == NULL und get\_color(x) == RB\_TREE\_RED terminieren den Algorithmus sofort. Die erste Bediengung trifft genau dann zu, wenn die Wurzel entfernt wird. Danach entsteht allerdings der leere Baum, der nach Definition balanciert ist, also muss man hier nichts mehr tun. Da die Eigenschaften von RBT beim Löschen nur dann verletzt werden, wenn man einen schwarzen Knoten entfernt, kann man auch sofort abbrechen, wenn die Farbe von x rot ist, was der zweiten Bediengung entspricht.

Alle anderen Zweige des if-Konstrukts entsprechen nun den 4 Fällen. Wie diese sich genau aufbauen, und warum sie so definiert sind, wurde bereits in Kapitel 2 beschrieben, deswegen wird dieser Teil hier nicht nochmal im Detail erklärt.

Was es noch anzumerken gibt, ist, dass der Fall 2 ebenfalls zum Terminieren des Algorithmus führt, weswegen sich dort ein break am Ende des Codeblocks befindet. Es ist durch die Definition des Algorithmus sichergestellt, dass dieser immer terminiert, also irgendwann die Wurzel erreicht oder den Fall 2 (siehe Kapitel 2).

Das untere Listing zeigt die gesamte Implementierung der Funktion.

```
while(1) {
      if (x->parent == NULL) {
          break;
      } else if (get_color(x) == RB_TREE_RED) { break; }
        else if (get_color(get_sibling(x)) == RB_TREE_RED) {
          x->parent->color = RB_TREE_RED;
          get_sibling(x)->color = RB_TREE_BLACK;
          rotate(x->parent, get_direction(x), rbtree);
      } else if (get_color(get_nephew(x)) == RB_TREE_RED) {
          get_sibling(x)->color = x->parent->color;
10
          x->parent->color = RB_TREE_BLACK;
          get_nephew(x)->color = RB_TREE_BLACK;
12
          rotate(x->parent, get_direction(x), rbtree);
13
14
15
      } else if (get_color(get_niece(x)) == RB_TREE_RED) {
          get_niece(x)->color = RB_TREE_BLACK;
          get_sibling(x)->color = RB_TREE_RED;
17
          rotate(get_sibling(x), !get_direction(x), rbtree);
```

## 3.6 Generische Baumtraversierung

Wie schon in der Einleitung erwähnt, bieten BTs die Möglichkeit, Daten geordnet zu speichern. Nun benötigt man auch Möglichkeiten, auf die Daten in einer bestimmten Reihenfolge zuzugreifen. Grundsätzlich gibt es 3 Optionen, die man als Traversierung bezeichnet nämlich Inorder-, Preorder- und Postorder-Traversierung. Alle diese Algorithmen sind rekursiv definiert. [Sed90, S. 44ff] Der untere Pseudocode stellt dar, wie sie funktionieren.

### Algorithm 3 Traversierungs-Algorithmen

```
1: procedure Preorder(nodeptr, VISIT)
       if noteptr == NULL then return
3:
       VISIT(noteptr)
       PREORDER(noteptr \rightarrow left)
4:
       PREORDER(noteptr \rightarrow right)
6: procedure Inorder(nodeptr, VISIT)
7:
       if noteptr == NULL then return
8:
       INORDER(noteptr \rightarrow left)
       VISIT(noteptr)
9:
       INORDER(noteptr \rightarrow right)
10:
11: procedure Postorder(nodeptr, VISIT)
       if noteptr == NULL then return
12:
       POSTORDER(noteptr \rightarrow left)
13:
       POSTORDER(noteptr→right)
14:
       VISIT(noteptr)
15:
```

[Knu68, S. 318ff]

Dabei ist noteptr der Pointer der Wurzel des Unterbaums (der ganze Baum ist auch ein Unterbaum von sich selbst). Und VISIT stellt dabei eine Funktionspointer dar, der einen noteptr als Parameter akzeptiert und ebenfalls als Argument in die Traversierungsfunktionen gegeben wird. So ist es dem Nutzer möglich, eine bestimmte Funktion auf alle Knoten anzuwenden.

```
uint8_t inorder_traversel(struct RBTree *rbtree, void (*visit)(struct Node*))

{
    struct Node *current = rbtree->root;
    struct Stack *stack = create_stack(_calc_worst_case_height(rbtree));

while (current != NULL || !is_stack_empty(stack)) {
    if (current != NULL) {
        push(stack, current);
        current = current->left;
}
```

```
} else {
                struct Node *stack_node;
               pop(stack, &stack_node);
12
13
               visit(stack_node);
14
                current = stack_node->right;
           }
15
16
       free_stack(stack);
17
       return RB_TREE_SUCCESS;
18
19 }
```

Im oberen Listing kann man am Beispiel der Inorder-Traversierung erkennen, wie die Algorithmen iterativ implementiert wurden. Anstatt den Hardware-Stack zu verwenden, wurde ein Software-Stack struct Stack \*stack implementiert. In diesen werden jeweils die noch zu besuchenden Unterbäume gepushed, und wenn der aktuelle Knoten current NULL ist, wird ein neuer Knoten aus dem Stack geholt. Diese Vorgehen simuliert das verhalten einer rekusiven Funktion, jedoch besteht bei sehr großer Rekursionstiefe nicht die Möglichkeit eines Stackoverflow. Die anderen Traversierungsarten wurden auf die selbe Weise implementiert.

Es kommt auf die genutzte Traversierungsart an, in welcher Reihenfolge man die Knoten besucht. Wenn man Inorder nutzt, dann bekommt man sie nach Schlüsseln aufsteigend sortiert. Das kann man z.B. dafür nutzen, die Schlüssel in geordneter Reihenfolge auszugeben. Bei der Postorder Traversierung wird die Wurzel des Unterbaums als besucht. So kann man Bottom-Up-Algorithmen implementieren, die bei den Blättern beginnen und die Wurzel des Baums als letztes behandeln.

Ein sehr praktischen Bespiel dafür ist das Freigeben der RBTs. Dabei müssen zuerst die Unterbäume aus dem Heap gelöscht werden und danach die Wurzel, weil man sonst die Unterbäume zwischenspeichern müsste, da die Pointer zu ihnen in der Wurzel gespeichert sind. Wenn man diese aber nun als erster freigibt, würde man keinen Zugriff mehr auf ihre Unterbäume haben.

```
void _free_node(struct Node *node)

{
    if (node->key != NULL) free(node->key);
    if (node->value != NULL) free(node->value);
    free(node);
}

void free_tree(struct RBTree *rbtree)
{
    postorder_traversel(rbtree, &_free_node);
    free(rbtree);
}
```

Hier wurde die VISIT-Funktion als \_free\_node implementiert, welche den Schlüssel und den Wert des besuchten Knotens freigibt und dann den Knoten-Struct selbst.

## 3.7 Fehlerbehandlung

Wie man in vielen vorhergenden Listings bereits sehen konnte, haben die meisten Funktionen als Ausgabetypen uint8\_t. (Die Fehlerbehandlung wurde aus den Listings jedoch meistens weggelassen, damit die sie nicht zu lang werden.) Das liegt, dass die Funktionen über den Ausgabewert Fehler an den Nutzer zurückgeben. Diese Fehler wurden als Macro definiert und durch sie können verschiedene Arten unterschieden werden.

```
1 #define RB_TREE_SUCCESS OU
```

```
2 #define RB_TREE_OUT_OF_MEM 1U
3 #define RB_TREE_KEY_ERROR 2U
4 #define RB_TREE_NULL_ERROR 3U
5 #define RB_TREE_DUPLICATE_KEY_ERROR 4U
```

In meiner Implementierung repräsentiert die 0 immer, dass es keinen Fehler gab. RB\_TREE\_OUT\_OF\_MEM wird von Funktionen verwendet, die dynamisch Speicher allozieren und das Betriebssystem nicht mehr genug zur Verfügung stellt. Die einzige Funktion, die den Fehler nutzt, ist insert\_node, nämlich genau dann, wenn kein neuer Knoten erstellt werden kann. Hierbei wird der Fehler allerdings nicht ausgegeben, sondern das Program wird mit exit(RB\_TREE\_OUT\_OF\_MEM) beendet. Ein RB\_TREE\_KEY\_ERROR wird von search\_node ausgegeben, wenn der zu suchende Schlüssel im Baum nicht existiert. Funktionen, die Pointer als Argumente akzeptieren, geben einen RB\_TREE\_NULL\_ERROR Fehler aus, wenn mindestens einer dieser Pointer NULL ist. Und ein RB\_TREE\_DUPLICATE\_KEY\_ERROR wird ausgegeben, wenn man insert\_node einen Schlüssel übergibt, der bereits im Baum existiert und man doppelte Schlüssel und implizites Überschreiben mithilfe der RB\_TREE\_DUPLICATE\_KEYS Macro deaktiviert hat.

# 4 Implementierungsvarianten

## 4.1 Rekursive Implementierung

Wie schon häufig im Kapitel 3 erwähnt, kann man auch die Suche und die Traversierung direkt als rekursive Funktionen, die sich selbst aufrufen implementieren. Das wurde auch durchgeführt. Im Kaptiel 5.3 kann man die Unterschiede bezüglich der Laufzeit der Programme sehen. Interssierte Leser können sich den Quelltext in der Datei rbtree\_h.c ansehen. Auf eine genauere Diskussion der Implementierung wird hier verichtet.

#### 4.2 Kekule Zahlen

Theoretisch gibt es auch eine Möglichkeit die Baumstruktur als Array von Knoten darzustellen und bessere Cacheladezeiten zu bekommen. Das größte Problem beim der Implementierung als verkettete Datenstruktur ist, dass die einzelnen Knoten stark verstreut im Heap abgespeichert sind und somit es zu vielen Cache Misses kommt. Diese Streuung kommt durch die Implementierung von malloc in der C -Standart-Bibliothek zu stande ("The order and contiguity of storage allocated by successive calls to malloc() is unspecified."[IEE]). Das verlangsamt das Programm. Man könnte als Array Implementierung eine spezielle Möglichkeit nutzen, Indizes für das Strukturieren des Arrays in Parent und Child zu nutzen. Die Wurzel würde den Index 0 erhalten. Die linken und rechten Children dann jeweils den Index  $2 \cdot n + 1$  und  $2 \cdot n + 2$  (n ist der Index des Parents). So erhält jeder Knoten einen eindeutigen Index und es gibt eine eindeutige Parent-Child-Beziehung. Leider ist der Red-Black-Tree kein vollständig balancierter Binary Tree, sodass es im Worst Case (Kapitel 6) passieren kann, dass sehr viel Speicher verschwendet wird, weil sehr viele Stellen im Array unbesetzt bleiben. Deswegen habe ich mich dagegen entschieden und habe die verkettete Variante der Datenstruktur implementiert.

#### 4.3 *n*-rote Knoten erlauben

Als Generalisierung von RBT könnte man sich einen n-RBT vorstellen, in dem es erlaubt ist, dass maximal n rote Knoten aufeinander folgen. ( $n \in \mathbb{N}$ ). Ich vermute, dass dadurch die Zeit, die das Löschen und Einfügen in den Baum benötigen, verringert würde, weil die Fixup-Algorithmen nicht so oft ausgeführt werden müssten bzw. eher terminieren könnten. [Bay72, S. 301] Nachteil ist, dass die

Länge eines farblich alternierenden Pfades im n-RBT n+1-mal so lang werden kann, wie die eines auschließlich schwarzen Pfads. (Ohne Beweis). Das würde die Performance der Suche der Datenstruktur wieder verschlechtern und da die Suche viel häufiger gebraucht wird als das Einfügen und Löschen ist der n-RBT mit n>0 keine gute alternative zum 0-RBT. Ich konnte auch keine Implementierungen von ihm finden. Eine Implementierung und richtige Benchmarks müssten durchgeführt werden, um die hier aufgestellten Behauptungen zu belegen, was aber aus Platz und Zeitgründen nicht durchgeführt wurde.

## 5 Benchmarks

Nun da erklärt wurde, wie sich RBTs von BTs und berschrieben wurde, welche komplizierten Operationen durchgeführt werden müssen, damit der RBT balanciert wird, stellt sich natürlich die Frage, ob dadurch wirklich eine bessere Laufzeit erzielt wird. In den folgenden 2 Abschnitten geht es darum, zu überprüfen, wie sich die Implementierung laufzeittechnisch verhält, wenn man eine große Anzahl an Knoten in die Datenstruktur einfügt. Es soll verglichen werden, ob die RBT tatsächlich schneller sind als die BT und ob meine Behauptung, dass Iterativ schneller als Rekursiv zumindest in diesem Fall stimmt.

## 5.1 Durchführung

Für die Benchmarks wurde im C -Code eine main-Funktion erstellt, die die Anzahl an Knoten, mit denen getestest werden soll als Kommandozeilenparameter erwartet. Anschließend werden zufällig zwei Arrays erstellt, die mit zufällig generierten Daten befüllt werden. Das erste enthält Daten, die in die Bäume eingefügt werden sollen und das zweite Daten, nach denen gesucht wird.

Begonnen wird mit dem RBT. Er wird zuerst mit den Daten befüllt, danach wird nach den Schlüsseln im zweiten Array gesucht. Dann wird seine Höhe bestimmt (welche ein sehr wichtiges Kriterium für die Laufzeit ist) und am Ende werden die Knoten alle wieder entfernt. Die Zeit, die die Operationen brauchen, wird direkt im Code gemessen und dann in den stdout ausgegeben im CSV Format. Die selbe Prozedur wird anschließend auch noch für den BT durchgeführt. Das testen mit verschiedenen Knotenanzahlen wurde durch ein Pythonscript automatisiert, welche das Programm kompieliert und dann mit verschiedenen Knotenanzahlen ausführt. Begonnen wird dabei bei 100.000 Knoten und das wird in Schritten von 50.000 bis auf 2.000.000 erhöht. Damit zufällige Schwankungen ausgeschlossen werden, wird jeder Test mit einer bestimmten Anzahl 15 mal durchgeführt und am Ende wird der Durchschnitt der Messwerte gebildet.

### 5.2 Red-Black-Tree vs. Binary Tree

Besonders wichtig ist es zu zeigen, dass unsere "Verbesserung"normalen Binary Trees tatsächlich performanter ist. In nebenstehender Abbildung kann man die Ergenisse des Benchmarks erkennen. Die Graphen, die mit dem Index rb beschriftet sind, sind die des RBT und die anderen gehören zum BT. Man kann erkenne, dass alle Operationen beim RBT grundsätzlich schneller als die der Standardimplementierung sind. Der Unterschied zwischen den beiden Datenstrukturen ist nicht konstant sondern nimmt mit steigender Anzahl an Knoten immer weiter zu.

Den Grund dafür kann man sehen, wenn man die Höhen der beiden Bäume vergleicht. Man kann sehen, dass sich der RBT viel näher an der Höhe des vollständig balancierten Baumes befindet, als der BT. Das sorgt dafür, dass man beim RBT im Durchschnitt nicht so viele Vergleiche benötigt, bis man den Knoten erreicht, den man

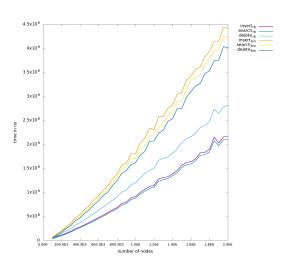


Abbildung 13: Vergleich Laufzeit RBT/BT

sucht oder einen NULL-Pointer, bei dem man einen neuen Knoten in den Baum einfügt. Das macht sich in den Benchmarks eindeutig bemerkbar.

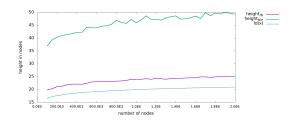


Abbildung 14: Vergleich der Höhen

Eine weiter interessante Beobachtung ist, dass die Suche und die das Einfügen beim RBT ungefähr gleich schnell sind, während das Löschen etwas langsamer als diese beiden Operationen ist. Einen so starken Unterschied gibt es beim BT nicht. Meine Hypothese dafür ist, dass das Rebalancieren beim Löschen von Knoten sehr viel langsamer ist, als das Rebalancieren beim Einfügen, weil der Algorithmus häufig den ganzen Baum bis zur Wurzel durchgeht.

#### 5.3 Recursive vs. Iterativ

Eine wichtige Frage, die sich während der Implementierung gestellt hat, ist, ob man die Operationen vom RBT iterativ oder rekursiv implementiert. Rekursion wäre zwar die erste Sache, an die man dabei denkt, weil die Defintion von Bäumen auch meistens rekursiv ist. Außerdem werden meistens auch alle Algorithmen rekursiv beschrieben. Das Problem daran ist, dass durch sehr große Rekursionstiefe eventuell Leistungsprobleme entstehen können und teilweise auch sehr viel Speicher nötig ist. Deswegen wurde, wie schon in vorhergenden Kapiteln beschrieben, eine iterative und eine rekursive Version der Datenstruktur erstellt, um diese zu vergleichen. Das Benchmark wurde wie in vorgehenden Abschnitt durchgeführt 5.2 nur wurden hier die 2 verschiedenen Versionen der Programms getestet. Dafür wurde das Pythonscript verändert, sodass es zuerst die iterative Variante kompiliert und die Tests durchführt und in eine Datei schreibt und anschließend die Rekursive.

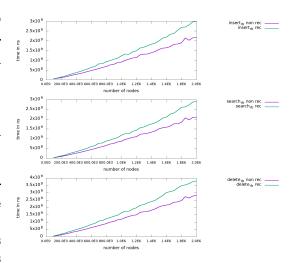


Abbildung 15: Vergleich Rekursive/Iterative Implementierungen

Die Ergenisse sind in nachfolgenden Graphen in Abbildung 15 zu sehen. Es gibt jeweils einen Graph für die Suche, das Einfügen und das Löschen.

Man kann in allen drei Fällen erkennen, dass die iterative Variante (non rec) ab einer sehr großen Anzahl von Knoten konsistent schneller ist als die Rekursive (rec). Meine Vermutung ist, dass es bei sehr großen Bäumen mit einer sehr großen Baumhöhe sehr viele Stackframes aufgebaut und auch wieder abgebaut werden müssen, wenn der rekursive Code ausgeführt wird. Bei meiner anderen Implementierung gibt es einen Softwarestack, welcher nur die nötigen Daten speichert und sich auch nicht vergrößern muss, weil er schon mit der richtigen Größe erstellt wird. Das könnte für den Signifikanten Unterschied in der Laufzeit der beiden Varianten führen.

## 6 Zeitkomplexität

Der RBT hat im Normal Case (NC) erstmal die selbe Komplexität wie der BT. Dort gibt es keine Verbesserung. Was man jedoch sehen kann, ist, dass im Worst Case (WC) die Komplexität von O(ld(n)) erhalten bleibt, während sie beim BT zu O(n) wird. Das liegt daran, dass die Standardimplementierung der Binary Trees keine Balancierung vornimmt. D.h. wenn man Daten in sortierter Reigenfolge einfügt, erhält man eine Linked List, weil immer nur einer der Unterbäume besetzt wird, je nachdem ob die Daten aufsteigend oder absteigend sortiert sind. Die Eigenschaft, dass man nach jedem Vergleich ca. die Hälfte der Daten nicht mehr abarbeiten muss, geht dadurch verloren. Nun ist es so, dass man Baumstrukturen genau zum effizienten Suchen verwenden möchte. Aus diesem Grund ist es besonders wichtig, dass man die schnelle Suche auch im Worst Case beibehält.

Abbildung 16: Zeit-Komplexität

-	Suche	Einfügen	Löschen
Binary Tree (NC)	O(ld(n))	O(ld(n))	O(ld(n))
Binary Tree (WC)	O(n)	O(n)	O(n)
Red Black Tree (NC)	O(ld(n))	O(ld(n))	O(ld(n))
Red Black Tree (WC)	O(ld(n))	O(ld(n))	O(ld(n))

Der WC beim RBT wird dann erreicht, wenn es einen alternierenden Pfad gibt, d.h. einen Pfad, in dem sich die Farben den Knoten immer abwechseln. Dieser kann die doppelte Länge im Vergleich zu einem Pfad erreich, in dem sich nur schwarze Knoten befinden. Dieses Beispiel zeigt auch nochmal schön, dass es sich bei RBT nicht um vollständig balancierte Bäume handelt, sondern nur um balancierte Bäume, die den WC zu einer linearen Datenstruktur zu werden, vermeiden. In der unteren Abbildung sind die Knoten, in der eine dick gedruckte Linie **endet** jeweils rot und alle anderen schwarz.

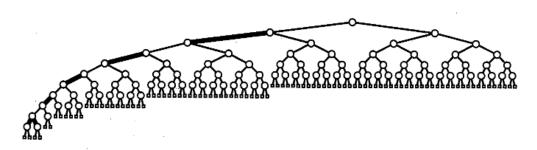


Abbildung 17: Worst Case RBT: Pfad mit alternierender Farbe

[Sed90, S. 228]

# Fußnoten

<sup>1</sup>Die Worst-Case-Höhe wird für eine kleine Optimierung benötigt. Im Kapitel 3.6 wird beschrieben, wie man die Bäume traversiert. Das ist normalerweise eine rekursive Operation, die ich jedoch iterativ implementiert habe. Dafür werden Stacks benötigt, die sich dynamisch vergrößern, falls sie überlaufen würden. Ich habe diese Stacks jedoch so implementiert, dass man sie mit einer initialen Größe erstellen kann. Die Worst-Case-Höhe des Baums gibt nun ungefähr die größte Rekursionstiefe an, welche bei mir der größten Anzahl an Elementen auf dem Stack entspricht. Somit kann ich dem Stack von Anfang an schon genug Platz geben, sodass er sich nicht so oft vergrößern muss, was mit einem Aufruf von reallocarray() verbunden. Dabei wird ein großer Speicherbereich kopiert, was das Programm unnötig verlangsamt, wenn man zu oft mehr Speicher im Stack benötigt.

# Literatur

- [Bay72] R. Bayer. Symmetric binary b-trees: Data structure and maintanance algorithms. *Acta Informatica*, 1:290–306, 1972.
- [CLRS09] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, and Clifford Stein. *Introduction to Algorithms, Third Edition*. The MIT Press, 3rd edition, 2009.
- [IEE] The open group base specifications issue 7, 2018 edition ieee std 1003.1-2017 (revision of ieee std 1003.1-2008). https://pubs.opengroup.org/onlinepubs/9699919799/functions/malloc.html, zuletzt besucht 29.09.2021.
- [Knu68] Donald E. Knuth. The Art of Computer Programming Volume 1 Fundamental Algorithms. Addison-Wesley Professional, 3 edition, 1968.
- [San08] Kurt Mehlhorn & Peter Sanders. Algorithms and Data Structures. The Basic Toolbox. Springer Verlag, 2008.
- [Sed90] R. Sedgewick. Algorithms in C. Addison-Wesley Professional, 1990.
- [YTD] Red-black tree deletion data structures and algorithms 34. https://www.youtube.com/watch?v=bDT1woMULVw, zuletzt besucht: 12.10.2021.